

UNIVERSITÉ PAUL-VALÉRY MONTPELLIER 3

Département de MIA SHS - UFR VI

RAPPORT DE STAGE

**Trajectoires résidentielles des habitants de la rue de la République
(Marseille)**

Présenté par :

Mélissa BOCCACCIO (22400372)

Tuteur de stage :

Jean Stéphane BORJA

Enseignants référents :

Marine DEMANGEOT et Jérôme PASQUET

JUIN 2026

Table des matières

1. Introduction	3
1.1 Structure d'accueil	3
2. Contextualisation	4
2.1 Rue de la République	4
2.2 Projet ENCRE	5
3. Problématique et enjeux de la structure	6
3.1 Fonction historique de la rue de la République	6
3.2 Data Paper	7
4. Travail réalisé	8
4.1 Compréhension de la rue	8
4.2 Base de données	8
4.3 Data Paper	9
4.4 Exploration	11
4.5 Redressement de l'échantillon	12
4.6 Analyse exploratoire	15
4.7 Typologie des trajectoires résidentielles	18
4.7.1 Population	18
4.7.2 Période observation	19
4.7.3 Longueur de séquence	20
4.7.4 État	20
5. Perspectives du stage après le rendu du rapport	22
5.1 Fin typologie trajectoire résidentielle	22
5.2 Analyse des trajectoires résidentielles	22
5.3 Problématique	22
6. Conclusion	23
7. Annexes	24
8. Bibliographie	29

1. Introduction

Le terme de « cycles de vie » désigne un modèle liant les déménagements aux étapes linéaires de la vie familiale. Le mariage par exemple, qui amène à la naissance des enfants et à l'achat d'une maison en banlieue, puis quelques années plus tard le départ des enfants arrive et les couples retournent en centre-ville ou dans un logement plus petit.

Puis les chercheurs se sont rendu compte que la vie n'était plus une ligne droite, en effet avec la diversification des structures familiales (divorces, familles monoparentales, recompositions) et les crises économiques, le terme « cycle » ne correspondait plus à la réalité. « Trajectoire » utilisé généralement en physique pour parler de l'histoire d'un point dans l'espace, a donc été utilisé comme remplaçant. En sciences sociales, la trajectoire résidentielle désigne quant à elle la succession des logements occupés par un individu ou un ménage au cours de sa vie, ainsi que les motifs de ces changements.

Au cours des dernières années, la question de l'analyse des trajectoires résidentielles est devenue un enjeu majeur des sciences sociales.

L'analyse des trajectoires résidentielles s'est développée à partir des années 1980, elle est la cause de trois facteurs. Dans un premier temps, la sociologie se rend compte que les trajectoires résidentielles ne peuvent pas être analysées seules, elles s'analysent avec les trajectoires professionnelles et familiales. Ensuite, la crise de l'emploi et l'explosion des prix de l'immobilier ont rendu les parcours résidentiels beaucoup moins généralisables, ce qui rend leur analyse cruciale afin de comprendre les phénomènes en cours, surtout pour les politiques publiques. Enfin, la révolution des outils statistiques et des méthodes d'enquête a permis de mieux comprendre les complexités des trajectoires. Cet essor de l'analyse est donc une continuité des progrès techniques et des questions théoriques arrivant dans le monde des sciences humaines et sociales.

Aujourd'hui, analyser une trajectoire résidentielle ne consiste plus seulement à lister des adresses, on cherche à comprendre comment le statut familial influence le logement, ce qui est subi (expulsion, séparation), ce qui est choisi, et ce que les lieux d'habitation peuvent dire sur ceux qui les occupent. Mais aussi ce que les trajectoires résidentielles peuvent amener dans la compréhension de la fonction d'un espace.

1.1 Structure d'accueil

ESPACE (UMR 7300) est un laboratoire mixte de recherche entre le CNRS, l'université d'Aix-Marseille (AMU), l'université d'Avignon (AU) et l'université Côte-d'Azur (UniCA), implanté à Aix-en-Provence, Avignon, Nice et Saint-Christol-lès-Alès.

Créé en 1997, il se compose principalement de géographes, mais également de psychologues, de sociologues, d'économistes et d'informaticiens. Rattaché à deux instituts du CNRS (CNRS Sciences Humaines et Sociales à titre principal, et CNRS Écologie et Environnement à titre secondaire).

Spécialisé dans l'Étude des Structures, des Processus d'Adaptation et des Changements de l'Espace géographique, ESPACE étudie les interactions espace-nature-société et leur durabilité, à différentes échelles. Les recherches se distinguent par l'importance du développement d'outils et méthodes de l'analyse spatiale, de la modélisation, et de la théorisation pour la production de connaissances géographiques, mais également par une pratique d'interdisciplinarité dans les sciences de l'environnement.

Le stage, quant à lui, se déroule à Aix-en-Provence, sur le site du Technopôle de l'environnement Arbois Méditerranée. La fusion des trois universités d'Aix-Marseille, donnant naissance à Aix-Marseille Université, a eu lieu en 2012. À cette occasion, les équipes du DESMID (Université de la Méditerranée) et de Schuman (Université de Provence) ont été regroupées pour former l'unité ESPACE AMU, qui opère désormais sur trois sites : Schuman, Arbois et Arles.

Jean-Stéphane Borja, tuteur de ce stage, est sociologue et enseignant-chercheur associé à Aix-Marseille Université (AMU) et au CNRS au sein de l'UMR 7300 ESPACE. Ses travaux de recherche portent sur la sociologie des publics, les mobilisations collectives ainsi que les problèmes publics. Auteur de sa thèse intitulée « Vie et mort d'un problème public : Autour du problème de la rue de la République à Marseille ». Cela constitue un ancrage direct entre le cadre d'accueil de ce stage et son objet d'étude.

2. Contextualisation

2.1 Rue de la République

La rue de la République à Marseille a toujours représenté un enjeu urbain bien complexe.

Le projet de construction de cette rue commence en 1858. La ville veut relier l'ancien port, devenu trop petit, au nouveau port de la Joliette ouvert en 1853. La ville manquant de fonds, elle accepte une avance de la Société des ports de Marseille appartenant à Jules Mirès. Après la validation du projet par l'empereur Napoléon III en 1858, les travaux commencent en 1862. À partir de cette date, la démolition de l'ancien bâti et de l'épaisseur de la colline nécessite la destruction de 935 maisons, la disparition de 38 rues et le déplacement de 16 000 personnes. Les immeubles furent construits dans un style haussmannien dans le but d'attirer la bourgeoisie marseillaise dans cette nouvelle rue. (Voir annexe 1)

Mais la grande bourgeoisie rejette cette rue au profit de quartiers résidentiels périphériques, des lieux calmes avec jardins et sans mélange avec d'autres catégories sociales. L'installation des familles liées à l'activité portuaire se fait donc naturellement, ce qui amène également à un échec commercial : les commerces de prestige espérés ne se sont jamais vraiment installés. En 1872, la création de la SIM, Société Immobilière de Marseille, se fait dans le but de gérer la quasi-totalité des logements rue de la République.

Mais la SIM choisit progressivement une gestion passive à partir des années 1970-1980, gelant les investissements et l'entretien des immeubles, ce qui est supposé avoir entraîné une augmentation des logements vacants, délabrés ou squattés.

Pour remédier à cette dégradation, l'établissement public Euroméditerranée met alors en place une OPAH (Opération Programmée d'Amélioration de l'Habitat) afin de réhabiliter le bâti et d'attirer de nouveaux ménages. Cette dynamique provoque cependant des conflits d'intérêts entre les locataires en place et les nouveaux propriétaires immobiliers, notamment autour des stratégies de rénovation, avec des pressions visant à reloger massivement les locataires en place.

Parallèlement, une mobilisation citoyenne s'organise autour du collectif Un Centre Ville Pour Tous, qui dénonce les expulsions, les pressions immobilières et la perte de mixité sociale. Malgré plusieurs tentatives de redynamisation, la rue de la République peine encore aujourd'hui à trouver un équilibre.



Rue de la République actuelle

2.2 Projet ENCRE

L'association Un Centre Ville pour Tous (CVPT) accompagne depuis 2004 les habitants de la rue de la République dans le contexte des opérations de réhabilitation. En 2015, elle réalise un premier travail de terrain qui alerte sur la vacance massive des logements et des commerces, révélant l'absence d'évaluation sociale sérieuse de l'OPAH République par les pouvoirs publics.

Face à cette absence d'évaluation et dans la continuité du premier travail de 2015, l'association CVPT s'associe à une équipe de chercheurs d'Aix-Marseille Université, mais également à une cinquantaine d'étudiants de licence et master en géographie, architecture, sociologie, urbanisme de quatre universités à Marseille, Paris, Montpellier. En 2017, elle lance le projet ENCRE, une enquête qui cherche à comprendre qui sont réellement les résidents rue de la République à Marseille et leur cadre de vie. Le but est de récolter des données sur les résidents afin de répondre à la problématique : « Qui sont les résidents de la rue de la République en 2017 ? »

Cette collecte repose sur un questionnaire en face-à-face conduit auprès de 317 ménages résidant dans le périmètre de l'OPAH République entre janvier 2016 et juin 2017. L'échantillon est construit en fonction du poids immobilier des différents types de propriétaires présents dans le périmètre (grands investisseurs comme ANF, bailleurs sociaux et copropriétés), en partant du principe que les stratégies de chaque propriétaire influencent directement le profil des ménages qui s'y installent. Le questionnaire comprend plusieurs aspects : un mélange de questions factuelles (surface, loyer, statut) et de questions ouvertes (motifs, satisfaction), ainsi qu'une approche multidimensionnelle couvrant le logement, les trajectoires résidentielles, les pratiques quotidiennes, la satisfaction et les caractéristiques des ménages. (Voir annexe 2)

L'objectif global de cette collecte était donc de qualifier le peuplement, comprendre les dynamiques résidentielles et analyser les conditions de vie dans la Rue de la République.

3. Problématique et enjeux de la structure

3.1 Fonction historique de la rue de la République

Pierre Fournier et Sylvie Mazzella, dans « Un bâti bourgeois pour des élites de second ordre » provenant de *Marseille, entre ville et ports. Les destins de la rue de la République* (2004), expliquent que la rue de la République fonctionne comme « un tremplin social pour des élites intermédiaires ».

Résider dans cette rue équivaut à une réussite sociale, notamment du fait de son architecture haussmannienne. Les populations s'installent d'abord dans un quartier populaire, tels que la Belle-de-Mai ou le Canet pour les Italiens immigrés dans la première moitié du XXe siècle ; le Panier pour les Corses venus s'installer sur le continent ; Belsunce et les Carmes pour les Maghrébins arrivés dans la seconde moitié du XXe siècle. Leur réussite professionnelle les amènent avec le temps à quitter les quartiers populaires et à résider ou à installer leurs activités sur la rue de la République. Le faire est un signe de réussite, la rue étant réputée prestigieuse. Constituant par là une élite de second ordre au sein de leur communauté, notamment dans le commerce pour lequel où la proximité du port est favorable à leur développement.

Puis une nouvelle vague d'immigrants vient derrière, prend leur place et reproduit le même parcours.

C'est ici que les données du projet ENCRE prennent tout leur intérêt, créer une typologie des trajectoires résidentielles des habitants en 2017, permet de s'intéresser à la façon dont les ménages donnent sens, à travers leurs trajectoires résidentielles, à la rue de la République. **Qu'en est-il de la fonction historique de la rue de la République décrite par Fournier et Mazzella en 2004 ?**

3.2 Data Paper

Un second enjeu accompagne également ce stage. En effet, l'un des acteurs du projet ENCRE, David Mateos Escobar (Chef de projet / Démonstrateur de ville durable à la Métropole Aix-Marseille-Provence) suit l'avancement de ce stage et avait pour finalité la publication de la base de données de 2017 dans un Data Paper.

Un Data Paper est un article scientifique qui comporte une description détaillée d'un jeu de données, les métadonnées, la méthode ayant permis son obtention et le potentiel de réutilisation de celui-ci. Il propose également un lien d'accès aux données. Il ne décrit pas de résultats de recherche et ne contient ni discussion ni conclusion.

L'émergence du Data Paper est due à quatre grands facteurs : la crise de la reproductibilité, l'explosion du volume des données et du numérique, le mouvement « Open Science » et le problème de reconnaissance. En effet, dès le développement des sciences empiriques au XX^e siècle, la multiplication des études quantitatives a révélé un problème récurrent : de nombreuses études ne pouvaient être reproduites faute d'accès aux données brutes. L'explosion du numérique s'accompagne du début des revues spécialisées. L'une des premières initiatives marquantes est la création de journaux comme *Earth System Science Data* (ESSD), qui visait à donner une valeur scientifique au partage de jeux de données massifs en géosciences (2008-2009). Le format se prolifère avec le lancement de revues « data-only » par de grands éditeurs (comme *Scientific Data* de Nature Research en 2014). Dans cette continuité, chaque jeu de données reçoit un identifiant pérenne et citable. En 2016, le principe FAIR (Facile à trouver, Accessible, Interopérable, Réutilisable) est formalisé, traduisant une pression croissante, éthique, politique et institutionnelle, pour rendre les données publiquement accessibles. Cela permettait également de donner aux acteurs qui ont permis la récolte des données, peu cités jusqu'alors, davantage de reconnaissance, de même pour les données elles-mêmes, aussi importantes que les articles qui les explicitent.

La même année, l'État français rend obligatoire le dépôt des données publiques pour toute recherche financée à plus de 50 % par des fonds publics (État, collectivités, UE) et publiée dans un périodique annuel (Loi pour une République Numérique).

Dans le contexte de ce stage, cela permet de rendre la base de données accessible et réutilisable par tous (habitants, étudiants, chercheurs ou acteurs locaux), de faire connaître le projet, de valoriser les données déjà collectées et, potentiellement, de relancer l'intérêt autour de l'enquête, tout en étant dans la continuité des valeurs de l'association Un Centre Ville Pour Tous.

4. Travail réalisé

4.1 Compréhension de la rue

Dans un premier temps, avant même le commencement du stage (et par la suite au début du stage), une compréhension de la complexité de la rue de la République et des politiques marseillaises ont dû s'imposer. Mais également comprendre le projet ENCRE, d'avoir du recul sur la provenance de la base de données. De nombreuses lectures ont donc été réalisées pour construire ce cadre d'analyse. L'ouvrage de Peraldi et Samson, *Gouverner Marseille. Enquête sur les mondes politiques marseillais*, a permis de comprendre les enjeux des politiques et des structures entre différentes classe sociale dans Marseille, avec les marchands de sommeil, le clientélisme des pauvres... *Marseille, entre ville et ports, Les destins de la rue de la République* constitue la référence centrale de ce stage notamment le chapitre de Fournier et Mazzella consacré au « bâti bourgeois pour des élites de second ordre » (p. 103-119), qui éclaire directement la trajectoire sociale de la rue et la notion d'élite de second ordre sur laquelle s'appuie ce travail. La question de l'éviction des populations résidentes est quant à elle traitée par Borja, Derain, Manry et Galmot dans *Attention à la fermeture des portes ! Citoyens et habitants au cœur des transformations urbaines*, publié aux Éditions Commune en 2010. Enfin, le numéro spécial du collectif *Un Centre-Ville Pour Tous*, intitulé « Onze après... et toujours inachevée », offre un regard militant et documenté sur l'état de la rue plus d'une décennie après le lancement de l'OPAH. Une grande partie du projet ENCRE est quant à elle expliqué dans le carnet de bord dédié à l'enquête, présent sur le site « <https://encre.hypotheses.org/> ».

Mais également une brève approche sur le terrain fut réalisée, aller sur la rue de la République et se rendre compte de la vacance, des commerces abandonnées...

Ces deux étapes permettent d'interroger et de faire valoir des hypothèses cohérentes avec le statut de la rue. Elles permettent également d'utiliser la base de données et faire des statistiques en ayant le contexte derrière, ce qui amène également une facilité d'usage.

4.2 Base de données

La base de données utilisée lors du stage avait déjà été retravaillée lors de la première enquête de 2017 et comptait 285 variables, contenant des variables brutes et des variables recodées. Une nouvelle préparation a ensuite été réalisée pour rendre son utilisation plus fluide et exploitable dans le cadre du stage.

La première étape a consisté à renommer un grand nombre de variables afin d'obtenir des noms plus courts, cohérents et faciles à manipuler dans Python. Cela évite les intitulés trop longs et permet de travailler plus efficacement.

Un nettoyage des variables numériques a ensuite été effectué : loyer, superficie, âge, satisfaction, revenu, ancienneté, etc. Toutes ont été converties au bon format, et les valeurs impossibles ou incohérentes ont été transformées en valeurs manquantes.

Les variables catégorielles ont également été harmonisées. L'écriture a été uniformisée (suppression des espaces inutiles, capitalisation, cohérence des catégories), ce qui permet d'éviter les doublons liés à des variations d'écriture.

Certaines variables ont été reconstruites ou dérivées pour faciliter les analyses telles qu'un mapping du type de logement vers le nombre de pièces, des indicateurs comme les m² par personne, le loyer par personne ou une satisfaction moyenne calculée à partir de trois questions, une correction de l'ancienneté lorsque l'information n'était pas renseignée, en la recalculant à partir de l'année d'emménagement.

Enfin, plusieurs tranches ont été créées (âge, revenu, loyer, superficie, ancienneté) grâce à des découpages en intervalles ordonnés. Ces catégories facilitent les analyses exploratoires et permettent de comparer plus facilement les profils des habitants.


L'ensemble de ces opérations a permis d'obtenir une base propre, cohérente et directement exploitable pour la suite du travail statistique, tout en restant fidèle à l'esprit exploratoire du stage.

4.3 Data Paper

Pour le travail autour du *data paper*, plusieurs recherches ont été menées afin de comprendre son apparition, ses usages, son utilité et les étapes nécessaires à sa création en vue d'une publication dans un data journal. La partie concernant son émergence et ses fonctions est développée dans la contextualisation (Partie 2).

La publication d'un *data paper* suit plusieurs étapes essentielles :

- Choix de la revue : la revue détermine le modèle d'article, les standards disciplinaires, les formats attendus et parfois les entrepôts recommandés. Le choix dépend du domaine scientifique et des futurs utilisateurs des données.
- Choix d'un entrepôt de données et obtention d'un DOI (Digital Object Identifier), indispensable pour rendre les données trouvables, citables et reconnues scientifiquement.
- Rédaction du *data paper* selon le modèle imposé par la revue.
- Soumission et évaluation par les pairs, suivies des éventuelles corrections et de l'acceptation. – attribution d'un identifiant au *data paper*, puis publication.



D'après Candela, L., Castelli, D., Manghi, P., & Tani, A. (2014). "Data journals: A survey" *Journal of the Association for Information Science and Technology* [En ligne]. 2015

Le travail réalisé a également consisté à lister l'ensemble des éléments nécessaires à l'écriture d'un *data paper*, en s'appuyant sur les modèles proposés par les revues et sur la littérature existante.

Une étape importante a ensuite été de sélectionner un entrepôt et une revue adaptés au domaine scientifique, les sciences humaines et sociales et aux objectifs de diffusion, accessibles à tous sans frais... À la suite d'un entretien avec Marie-Laure Tremelo (ingénieure CNRS spécialisée dans l'acquisition, le traitement et la gestion de données sur les interactions hommes-environnement, et impliquée dans la vérification de *data papers*), le choix s'est orienté vers la revue *Data & Corpus* et l'entrepôt NAKALA, reconnu pour son adéquation avec les données en SHS. Ces choix permettent d'assurer une publication conforme aux standards, accessible, et cohérente avec les pratiques de la communauté scientifique concernée.

Nakala est un entrepôt de données de recherche dédié aux Sciences Humaines et Sociales, ouvert en 2014 pour répondre aux besoins de préservation et de diffusion des données en SHS. Les données y sont stockées sur des serveurs gérés par Huma-Num et hébergés en France, au centre de calcul de l'IN2P3.

Data & Corpus, la revue des données en SHS, accueille des travaux issus de toutes les disciplines des sciences humaines et sociales, avec un fort accent sur l'interdisciplinarité. Créée en 2024, elle s'inscrit pleinement dans la logique de la science ouverte. Elle est éditée par l'Université de Lorraine, soutenue par la MSH Lorraine, et développée et hébergée par Huma-Num.

Après ces recherches et présenter les power points réalisés sur le sujet, j'ai également listé l'ensemble des éléments nécessaires pour le dépôt et pour la revue, afin de préparer la construction du *data paper*. J'ai commencé à décrire les métadonnées des 285 variables de la base.

Malheureusement, la création du *data paper* a été mise en pause en attendant un entretien avec l'association Un Centre Ville Pour Tous, propriétaire et commanditaire de la base de données. Cet entretien devrait permettre d'obtenir l'autorisation de publication. À ce jour, le rendez-vous n'a pas encore eu lieu.

Ce travail m'a tout de même permis de me familiariser avec plusieurs notions importantes, comme les principes FAIR, de consulter différents articles et bases de données, et de mieux comprendre l'émergence de la science ouverte dans les pratiques de recherche actuelles.

4.4 Exploration

Ce stage se place avant tout dans un contexte exploratoire. L'utilisation de la base de données était nécessaire pour produire de la connaissance, mais les questionnements autour de cette connaissance (ce qu'elle permet réellement de comprendre) étaient encore plus important.

L'objectif initial était de mieux saisir le public de la Rue de la République : qui y habite en 2017, depuis quand, pour quelles raisons...

Cependant, l'enjeu principal n'était pas uniquement dans cette première compréhension de la rue. Pendant plusieurs semaines, la recherche d'une problématique pertinente et d'une approche adaptée à cette base de données a été une étape cruciale. Cela a impliqué la constitution d'une bibliographie, la réalisation de lectures théoriques ainsi que des analyses exploratoires afin de tester différentes pistes. Mais également des réunions hebdomadaires avec mon tuteur de stage ainsi que David Mateos Escobar pour dans un premier temps discuter de l'avancement du travail réalisé, et dans un second temps se mettre d'accord sur la suite du travail, resserrer un questionnement... Cela a également permis de garder une trace de mon travail, dans des rapports et des power point (sur le data paper, le redressement...).

La formulation de la question de recherche constituait la partie la plus importante du début du stage. Elle devait être en lien avec le projet ENCRE, contribuer à la production de connaissance, et surtout donner un sens aux analyses statistiques afin d'éviter de "faire des statistiques pour faire des maths", sans savoir ce que l'on cherche.

Finalement, une question s'est précisée : « Qu'en est-il de la fonction historique de la Rue de la République décrite par Fournier et Mazzella en 2004 ? »

À partir de là, les analyses statistiques ont pu réellement commencer, guidées par une problématique claire.

4.5 Redressement de l'échantillon

La base de données ne contient que 337 individus, ce qui représente environ 1,81 % de la population réelle de la Rue de la République recensée par l'INSEE sur les IRIS (Ilots Regroupés pour l'Information Statistique) sélectionnés (337/18 592). Cette taille réduite rend l'échantillon non représentatif, ce qui limite la possibilité de généraliser les analyses sur les trajectoires résidentielles.

Pour généraliser et donner plus de robustesse aux résultats, il a donc fallu identifier une méthode statistique ou informatique permettant de rapprocher l'échantillon de la population réelle. Plusieurs pistes ont été explorées.

La génération d'individus par machine learning a d'abord été envisagée. Cette technique peut être pertinente dans des bases très quantitatives, où l'objectif est d'augmenter artificiellement la taille de l'échantillon. Mais dans le cadre de ce stage, l'enjeu n'était pas d'augmenter le nombre d'individus pour "faire du volume". Ce qui importait, c'était de savoir si la fonction historique de la rue (ascension sociale pour élite de second ordre) existe encore, et dans quelle proportion, pas de créer artificiellement des profils qui n'existent peut-être pas.

Après ces recherches, les méthodes de redressement d'échantillon sont apparues comme les plus adaptées à la base et à la problématique. J'ai dû dans un premier temps me documenter pour comprendre à quoi cela correspond, ce que cela permet... mais également trouver quelle méthode de redressement serait la plus adaptée à notre base de données.

Le redressement est une technique statistique qui permet de corriger un échantillon pour qu'il représente mieux la population réelle. Cela consiste à affecter un poids à chaque répondant pour que l'échantillon pondéré ressemble à la population de référence on compare la distribution de l'échantillon à des données de référence (recensement, registre...). Cela permet dans un premier temps, de corriger les biais d'échantillonnage, comme dit précédemment l'échantillon collecté ne reflète pas la population cible, lors d'une collecte il y a des biais de sélection (certains groupes sont plus enclins à répondre) mais également des biais de non-réponse (une partie de la population choisit de ne pas participer). Dans un second temps cela permet d'améliorer la fiabilité et la généralisable des analyses. La méthode de redressement d'échantillon qui a été retenue pour la base est le calage sur les marges (Raking), le principe est simple, il faut ajuster les poids de façon itérative pour que les marges de l'échantillon coïncident avec les marges de la population. Pour chaque catégorie, on calcule un coefficient de redressement en utilisant cette formule :

$$\text{Poids} = \% \text{ Population cible} \div \% \text{ Échantillon brut}$$

Un ménage appartenant à un profil sous-représenté reçoit un poids supérieur à 1. Un ménage surreprésenté reçoit un poids inférieur à 1. Comme corriger une variable perturbe légèrement les autres, l'opération est répétée en boucle sur toutes les variables jusqu'à ce que toutes les proportions pondérées coïncident simultanément avec les proportions réelles. C'est la convergence de l'algorithme.

Pour appliquer ce raking, il a fallu définir la population cible. J'ai utilisé le recensement INSEE par IRIS du millésime 2017 (construit à partir des données 2015-2019).

La sélection des IRIS correspondant à la Rue de la République a été réalisée via Géoportail, en longeant toute la rue et en notant les IRIS concernés par le secteur ou par l'OPAH République.

Plus tard lors de la typologie des trajectoires, je me suis rendu compte que parmi les individus présents dans ma base de données que certains IRIS avaient été oubliés. Le redressement a donc été mis à jour.

Une fois ces IRIS identifiés, la base INSEE a été filtrée pour ne conserver que les habitants de ces zones. J'ai utilisé les variables disponibles dans le recensement qui correspondaient à des informations présentes dans notre base de données : le sexe, la tranche d'âge, et la catégorie socioprofessionnelle (PCS). Ces trois variables ont été retenues car elles sont à la fois disponibles dans les deux bases de données et structurantes pour décrire la population.

Pour chaque variable, les marges cibles ont été calculées à partir des colonnes du fichier INSEE. Pour le sexe, on somme le nombre d'hommes et le nombre de femmes sur l'ensemble des IRIS sélectionnés, ce qui permet d'obtenir la proportion de chaque modalité dans la population. Le même raisonnement est appliqué pour l'âge, avec six tranches : 18-24 ans, 25-39 ans, 40-54 ans, 55-64 ans, 65-79 ans, et 80 ans ou plus. Ces tranches ont été construites pour correspondre à celles déjà présentes dans notre base de données enquêtée. Pour la PCS, le fichier INSEE distingue huit catégories : agriculteurs exploitants, artisans-commerçants-chefs d'entreprise, cadres et professions intellectuelles supérieures, professions intermédiaires, employés, ouvriers, retraités, et autres sans activité professionnelle. Chaque proportion est arrondie à quatre décimales pour éviter des écarts de précision lors du calcul des poids.

Un point de traitement a été nécessaire côté base de données : les modalités de PCS renseignées par les enquêtés ne correspondaient pas exactement aux intitulés INSEE. Il a donc fallu créer une table de correspondance pour faire le lien entre les deux nomenclatures. Par exemple, la modalité "Étudiant" de notre base a été rattachée à "Autres sans activité professionnelle" dans la nomenclature INSEE, et "Cadres et professions intellectuelles supérieures" a été conservée telle quelle sous un intitulé raccourci. Une nouvelle colonne PCS_cale a été créée dans le dataframe pour stocker ces modalités harmonisées, utilisées ensuite dans le raking.

La fonction de raking codée en Python repose sur un algorithme itératif. Elle prend en entrée le *dataframe* avec les trois colonnes de calage, le dictionnaire des marges cibles pour chaque variable et chaque modalité, un nombre maximum d'itérations fixé à 200, un seuil de convergence fixé à un millionième et un paramètre de plafonnement. (Voir annexe 3)

Au départ, chaque individu reçoit un poids égal à 1. À chaque itération, on parcourt successivement les trois variables. Pour chacune, on parcourt chaque modalité : on identifie les individus qui lui appartiennent, on calcule leur proportion actuelle dans l'échantillon pondéré, et on multiplie leur poids par le rapport entre la proportion cible INSEE et cette proportion observée. Ce mécanisme est identique à la formule présentée plus haut. Corriger une variable perturbe légèrement les suivantes, c'est pourquoi l'opération est répétée jusqu'à ce que les poids ne bougent plus d'une itération à l'autre. L'algorithme s'arrête dès que le plus grand écart entre

les poids anciens et nouveaux est inférieur au seuil de convergence. En pratique, la convergence a été atteinte en quelques dizaines d'itérations.

Une fois les poids calculés, deux ajustements sont appliqués. Un plafonnement est d'abord effectué : aucun poids ne peut dépasser six fois la moyenne des poids, ce qui permet d'éviter qu'un individu très atypique ne prenne un poids excessif et ne fausse les analyses. Ensuite, les poids sont normalisés pour que leur moyenne soit égale à 1, ce qui facilite l'interprétation : un individu avec un poids de 2 compte deux fois plus qu'un individu avec un poids de 1 dans les analyses pondérées.

Pour vérifier la qualité du redressement, j'ai calculé les écarts absolus entre les proportions pondérées et les marges INSEE pour chaque variable. En théorie, ces écarts doivent être inférieurs à 0,5 point de pourcentage pour considérer le calage comme satisfaisant.

Pour l'âge, les résultats sont bons. Toutes les tranches affichent des écarts compris entre 0,30 % et 0,72 %, restant proches ou en dessous du seuil. La tranche "18-24" a nécessité une correction préalable : les individus de 16 et 17 ans présents dans la base ont été intégrés à cette tranche pour correspondre à la nomenclature INSEE, qui ne couvre que les 18 ans et plus. Sans cela, la tranche n'apparaissait pas dans la comparaison.

Pour la PCS, la majorité des catégories sont bien calées. Cadres (0,30 %), Employés (0,53 %), Ouvriers (0,04 %), Professions intermédiaires (0,30 %) et Retraités (0,30 %) sont tous sous le seuil. Les NaN sur "Agriculteurs exploitants" et "Artisans, Commerçants" indiquent simplement que ces catégories sont absentes de l'échantillon. En revanche, les "Autres sans activité professionnelle" affichent un écart de 2,1 %, le plus élevé de toutes les variables. Cela s'explique par une sur-représentation structurelle dans l'échantillon : 51 étudiants et 33 autres inactifs y sont recensés, soit environ 25 % de la base, contre une proportion bien moindre dans la population INSEE. Le raking corrige partiellement cet écart mais ne peut pas l'éliminer complètement tout en restant cohérent avec les deux autres variables.

Pour le sexe, les écarts restent autour de 2 % pour les deux modalités, malgré plusieurs corrections apportées au cours du processus. Un premier problème de nomenclature a été identifié : deux individus avaient une valeur "NaN" en guise de sexe. La ligne entièrement vide a été supprimée car elle correspondait à une ligne faussée importée depuis Excel. Pour le second individu, le sexe était inconnu et il aurait été méthodologiquement incorrect de lui en attribuer un arbitrairement, sa valeur a donc été convertie en NaN réel, ce qui l'exclut du calage sur le sexe et lui attribue un poids de 1,0 par défaut. Malgré ces corrections, l'écart résiduel de 2 % s'explique par la contrainte inhérente au raking : calibrer simultanément trois variables sur 337 individus crée des tensions entre les ajustements, et le sexe absorbe une partie de ces compromis. L'échantillon brut était pourtant très proche de l'INSEE sur cette variable (51,9 % de femmes contre 50,9 % en cible), ce qui confirme que cet écart relève des limites de l'algorithme sur petit échantillon et non d'un problème de collecte.

Ce point constitue un élément de vigilance méthodologique et ouvre plusieurs pistes de réflexion. Que se passerait-il si l'on retirait la variable sexe du raking ? Les autres variables se recaleraient-elles mieux, ou au contraire perdrait-on une information importante ? Existe-t-il des méthodes alternatives plus adaptées à un petit échantillon ?

Concernant les statistiques des poids, ils sont bien normalisés avec une moyenne exactement égale à 1. L'écart-type de 0,298 indique que les poids ne sont pas trop dispersés, et les valeurs extrêmes restent raisonnables : le poids minimum est de 0,349 et le maximum de 1,906, très loin du plafond de 6 fixé dans l'algorithme. Cela signifie qu'aucun individu n'a été surpondéré de façon problématique, et que le redressement reste stable et interprétable.

Au total, ce redressement présente des résultats solides sur l'âge et la majorité de la PCS. Les écarts résiduels sur le sexe et les "Autres sans activité professionnelle" sont documentés et explicables, l'un par les contraintes mathématiques du raking sur petit échantillon, l'autre par un biais de collecte structurel. Ces limites sont inhérentes à la base et non à la méthode, et elles seront prises en compte dans l'interprétation des résultats.

Cette démarche a tout de même permis de rendre l'échantillon plus cohérent avec la population réelle, et donc de produire des analyses plus solides pour répondre à la problématique.

4.6 Analyse exploratoire

Une fois le redressement effectué et les poids calculés, il a fallu reprendre les analyses exploratoires, cette fois en tenant compte des pondérations. Tout a été codé avec Google Colab afin de faciliter l'accès à l'analyse et aux graphiques à mon tuteur de stage et David Mateos Escobar, mais aussi cela permet de visualiser les graphiques simultanément et simplifie la lecture.

Cette étape permet d'abord d'avoir une vision globale de la population de la Rue de la République, qui y habite, depuis quand, quels sont les profils, combien de personnes vivent dans les logements, etc. Mais cette phase exploratoire sert aussi à préparer la suite, repérer les variables qui peuvent influencer les trajectoires résidentielles, identifier s'il existe des profils socio-démographiques associés à certains types de trajectoires, cela permettra de pousser la problématique et d'avoir une meilleure compréhension des trajectoires. Ces éléments seront développés plus tard dans la partie « travail à venir ».

Une première partie de l'analyse exploratoire s'est concentrée sur les résultats issus de la pondération. L'objectif était d'obtenir un premier portrait pondéré de la population de la Rue de la République, avant de poursuivre l'exploration avec des visualisations graphiques.

Pour les variables numériques, quatorze ont été retenus. On y retrouve les caractéristiques du logement et du ménage (âge, nombre de personnes, nombre de pièces, ancienneté, superficie, loyer, loyer/m², loyer par personne, m² par personne, montant de l'aide au logement, revenu mensuel) et les indicateurs de satisfaction (logement, immeuble, quartier, et une satisfaction moyenne).

Pour chaque variable, la moyenne pondérée est calculée avec *np.average*, en utilisant les poids issus du redressement. L'écart-type pondéré est ensuite calculé manuellement. Le tableau final indique aussi le nombre de valeurs valides et le pourcentage de valeurs manquantes, ce qui permet d'identifier rapidement les variables les moins renseignées.

On observe que l'âge moyen des habitants est de 45,1 ans (écart-type 19,5), ce qui traduit une population relativement adulte, avec tout de même une présence de jeunes actifs mais aussi de seniors. La taille moyenne des ménages est de 2,35 personnes, ce qui correspond à des ménages plutôt petits, cohérents avec la structure résidentielle du centre-ville.

La satisfaction moyenne (logement, immeuble, quartier) atteint 3,68/5, indiquant un niveau globalement positif mais avec des variations importantes selon les individus.

Certaines variables présentent toutefois un taux de données manquantes très élevé, comme le montant de l'aide au logement (76,6 %). Cela peut s'expliquer par plusieurs raisons : certaines personnes ne souhaitent pas communiquer cette information, d'autres ne savent pas précisément le montant, ou encore ne perçoivent aucune aide.

Pour les variables catégorielles, dix variables ont été analysées : le genre, la tranche d'âge, la PCS, le type de ménage, le statut d'occupation, le type de bailleur, la catégorie d'ancienneté, la situation historique, l'aide au logement et le projet de rester.

Pour chacune, les individus sont regroupés par modalité, puis leurs poids sont additionnés pour obtenir un effectif pondéré. La part de chaque modalité est ensuite calculée sur le total pondéré. Les valeurs manquantes sont systématiquement recodées en *Non renseigné* pour ne pas disparaître de l'analyse.

L'analyse pondérée met en évidence plusieurs tendances fortes concernant la population de la Rue de la République. La tranche des 25-39 ans apparaît comme la plus représentée (29,9 %), ce qui correspond à une population plutôt jeune, active, souvent en mobilité résidentielle. À l'inverse, les retraités représentent 18,7 % de la population pondérée. Leur part était probablement plus élevée avant 2017, avec le temps, les décès, les départs en EHPAD on réduit leur présence, un effet de turn over est apparu.

Plus de la moitié des habitants sont locataires sous la loi 1989 (52,9 %), un cadre juridique courant dans le parc privé classique. Les propriétaires ne représentent qu'une minorité (15,4%), ce qui montre que la rue reste un espace dominé par la location, avec une forte mobilité potentielle. Mais l'échantillon même si redressé ne montre pas la vacance de la rue, qui doit être pris en compte.

L'ancienneté dans le logement renforce l'idée de mobilité résidentielle, près de 38 % des habitants sont installés depuis moins de deux ans.

On peut formuler l'hypothèse que le turn-over observé entre les personnes âgées et la tranche des 25-39 ans s'est produit récemment : les départs naturels (décès, relogements, entrées en institution) auraient laissé place à une nouvelle génération d'habitants plus jeunes, plus mobiles, mais qui, une fois installés, expriment tout de même une volonté de stabilisation.

On peut aussi se demander si la mobilité résidentielle décrite par Fournier et Mazzella, la Rue de la République comme un espace marqué par des trajectoires ascendantes, est toujours d'actualité. Les résultats pondérés suggèrent que cette fonction historique pourrait en 2017 être moins présente, ou du moins plus nuancée.

Ces premières observations constituent des premières approches intéressantes pour introduire la problématique, surtout quand on se place dans un contexte exploratoire comme celui-ci.

Pour l'exploration avec des visualisations graphiques, plusieurs graphiques ont été réalisés, mais je ne présente ici que les plus pertinents.

Un premier exemple concerne les lieux de naissance. La variable brute contenait de nombreuses écritures différentes pour une même ville (ex. "Marseille", "13001", "marseille", etc.). Une fonction de nettoyage a donc été créée pour rendre une écriture unique. Ce premier graphique s'est intéressé aux lieux de naissance des résidents. Marseille domine avec près de 73 effectifs pondérés, ce qui confirme un ancrage local fort. L'Algérie arrive en deuxième position (~ 43 effectifs), suivie de la Tunisie et de Paris. On retrouve également des origines plus dispersées, Vietnam, Dakar, Comores, Portugal. Cela témoigne d'une diversité, même si l'ancrage marseillais reste fort présent.

Pour le graphique portant sur la répartition des PCS, on observe que les retraités (~63), les employés (~53) et les étudiants (~52) sont les trois groupes les plus représentés. Les professions intermédiaires comptent pour environ 41 effectifs pondérés, tandis que les cadres et les ouvriers restent présents mais minoritaires. Cette distribution montre une diversité d'emplois dans la rue, sans réelle catégorie dominante. Cette diversité rend particulièrement pertinent de lier la PCS aux trajectoires résidentielles, afin de voir si un profil professionnel est plus représenté qu'un autre dans une trajectoire type. Il sera donc essentiel d'examiner comment chaque PCS se distribue dans les trajectoires, et notamment d'observer le cas des professions intermédiaires, leur trajectoire pourrait révéler la mobilité ascendante, expliqué par Fournier et Mazzella. (Voir annexe 4)

Des visualisations autour du projet de rester ont été également réalisées, en fonction d'autres variables telles que l'âge, la pcs, l'ancienneté... Ces graphiques montrent que les 25–39 ans sont les plus mobiles avec une envie de partir plus prononcée, tandis que les 65–79 ans expriment une forte volonté de rester. Les retraités sont la catégorie la plus stable, alors que les professions intermédiaires apparaissent plus enclines à envisager un départ. L'analyse par ancienneté confirme elle une logique d'ancrage progressif, plus les habitants sont installés depuis longtemps, plus ils souhaitent rester. Ces résultats constituent un indicateur pertinent pour anticiper la continuité ou la rupture des trajectoires résidentielles. (Voir annexe 5/6)

Le graphique portant sur l'évolution des PCS selon l'ancienneté met en évidence une dynamique de peuplement très nette. Parmi les arrivants récents (0–2 ans), on retrouve principalement des étudiants, des employés et des personnes sans activité professionnelle, ce qui confirme la présence d'une population jeune et mobile dans les premières années d'installation.

À mesure que l'ancienneté augmente, la structure socioprofessionnelle se transforme progressivement, la part des retraités devient de plus en plus importante, jusqu'à dominer largement la tranche des 20 ans et plus. (Voir annexe 7)

Cette évolution illustre en partie le turn-over résidentiel déjà observé dans les autres analyses. Ce résultat est intéressant au regard de la problématique, car il montre que la rue de la République reste un espace marqué par des mobilités successives, où les trajectoires varient selon la PCS et le moment du parcours résidentiel.

Cette étape exploratoire m'a d'abord servi dans un premier temps à comprendre mieux les habitants, leurs profils, leurs conditions de logement, leurs anciennetés, mais aussi les dynamiques de turn-over qui structurent le quartier.

Elle a également permis d'identifier des éléments susceptibles d'influencer les trajectoires résidentielles futures, comme le projet de rester et la satisfaction qui donne un ordre d'idée.

Cette phase a aussi été l'occasion de repérer les variables qui pourront jouer un rôle important dans l'analyse des trajectoires, telle que la PCS, le lieu de naissance, le statut d'occupation, mais aussi d'autres variables moins racontées ici comme le type de bailleur ou la situation historique, qui restent pertinentes dans un contexte exploratoire. L'objectif est de garder en tête les dimensions susceptibles d'expliquer les parcours résidentiels.

4.7 Typologie des trajectoires résidentielles

Pour analyser des trajectoires résidentielles il faut dans un premier temps créer une typologie de trajectoires, cette étape est essentielle, elle permet de transformer des parcours individuels en catégories comparables afin d'identifier des trajectoires types. J'ai dans un premier temps fait de la bibliographie, principalement lu les travaux de Nicolas Robette, qui font référence à l'analyse de séquences et à la construction de typologies, *Tutoriel d'analyse de séquences* (2023), *Explorer et décrire les parcours de vie : Les typologies de trajectoires* (2011), *La construction de typologies de trajectoires* (2022). L'ensemble de cette bibliographie a permis de définir un cadre méthodologique solide pour la suite du travail : comprendre comment les trajectoires peuvent être codées, comparées et regroupées...

Cela m'a permis de lister les différentes étapes nécessaires à l'élaboration d'une typologie : définir la population étudiée, choisir la période d'observation, la longueur de séquence, identifier les états composant les trajectoires, sélectionner une mesure de dissemblance, déterminer une méthode de classification, puis fixer le nombre de classes retenu.

4.7.1 Population

Avant de définir la population d'observation, plusieurs questions se sont posées afin que le choix soit conforme à la question de recherche, fallait-il conserver l'ensemble de l'échantillon ou opérer une sélection préalable ? L'âge pouvait-il avoir un impact sur la trajectoire,

notamment pour les individus très jeunes, parfois encore vivant chez leurs parents ? Fallait-il exclure les profils considérés comme « atypiques » au regard de la problématique, comme les étudiants ou les ménages très mobiles ? Mais exclure ces catégories aurait risqué de biaiser l'analyse en ne conservant que des trajectoires déjà stabilisées ou « conformes » à l'hypothèse de mobilité ascendante.

Ces réflexions ont conduit à conserver l'intégralité de l'échantillon redressé, soit les 337 individus majeurs résidant dans le périmètre de l'OPAH en 2017. Notre objectif est d'interroger la persistance de la fonction historique de la Rue de la République, décrite par Fournier et Mazzella (2004) comme un « tremplin social pour des élites de second ordre ».

Pour évaluer si cette fonction est encore active, diminutive ou transformée, il est indispensable de conserver l'ensemble des profils présents dans le quartier. Exclure certains individus, étudiants, ménages précaires, trajectoires non ascendantes, aurait orienté les résultats.

La conservation de l'ensemble des 337 individus a nécessité un traitement spécifique des données manquantes, particulièrement fréquentes dans les questions rétrospectives (lieu de résidence antérieur, ancien statut d'occupation). Les algorithmes de classification tolérant mal les valeurs manquantes, une exclusion des lignes incomplètes aurait réduit la taille de l'échantillon et compromis la représentativité obtenue grâce au redressement. Les non-réponses vont donc être recodées sous la modalité « Non renseigné », considérée comme une information à part entière. Cette solution permet de préserver la robustesse statistique tout en laissant la classification regrouper, le cas échéant, des profils caractérisés par une absence d'informations sur leur passé résidentiel.

4.7.2 Période observation

Un entretien avec Hugo Botton a été réalisé afin de parler de la construction de la typologie des trajectoires résidentielles. Doctorant en sociologie, il réalise actuellement une thèse sur les trajectoires résidentielles des habitants des quartiers prioritaires. Ses recherches portent sur les inégalités socio-spatiales en milieu urbain et leurs implications en termes de politiques publique. Cet échange m'a permis d'avancer plusieurs choix méthodologiques, notamment la période d'observation et les catégorisations pertinentes pour définir les états de la trajectoire.

Avant cet entretien, plusieurs questions se posaient : fallait-il conserver tous les logements antérieurs ? Est-ce qu'un seul logement précédent suffisait ? Est-ce que cela risquait de masquer des informations importantes, surtout pour les individus déjà installés depuis longtemps dans la Rue de la République ? Et surtout, est-ce que cela allait empêcher de voir des trajectoires intéressantes, puisque beaucoup d'habitants étaient déjà dans la rue avant 2017 ?

Après l'entretien, l'accord a été de se concentrer sur un seul logement antérieur, pour plusieurs raisons. D'abord, recoder l'ensemble des anciens logements aurait été extrêmement long dans le cadre d'un stage, surtout pour les résidents marseillais dont il aurait fallu retrouver chaque IRIS de chaque résidence, nous verrons après pourquoi.

Ensuite, la dernière étape résidentielle avant l'installation actuelle peut déjà apporter des éléments de réponse à la problématique, notamment en termes de mobilité ascendante, de type de bailleur ou de statut d'occupation.

Je m'étais posé la question du risque : si beaucoup d'habitants vivaient déjà dans la Rue de la République, est-ce qu'on allait vraiment observer quelque chose ? Mais comme l'a souligné David Mateos Escobar, même dans ce cas, des variables comme le type de bailleur (en lien avec le projet ENCRE) ou le statut d'occupation permettent déjà de repérer des logiques d'ascension sociale.

Un autre argument important concerne les données manquantes. Utiliser tous les logements antérieurs aurait généré énormément de « Non renseigné », en effet certains habitants n'ont presque jamais déménagé, d'autres ne se souviennent plus de leurs anciens logements.

Avec seulement 337 individus, augmenter les états aurait rendu chaque parcours presque unique. Or, l'objectif d'une typologie est justement de faire ressortir des points communs, pour identifier 4 ou 5 grands profils types. Trop d'informations différentes auraient créé du bruit et empêché l'algorithme de repérer des ressemblances fortes.

Enfin, limiter la trajectoire à deux étapes (logement antérieur → logement actuel) permet aussi de réaliser plus facilement une analyse de transition, puis d'utiliser des méthodes comme l'ACM et la CAH, adaptées à ce niveau de complexité.

La période d'observation est donc désormais bornée par deux événements spécifiques, elle commence au moment de l'occupation du logement précédent et s'achève au moment du logement actuel.

4.7.3 Longueur de séquence

La longueur de la séquence correspond au nombre d'étapes qui composent le parcours résidentiel retenu pour l'analyse. Dans ce cas, elle est donc de 2, puisqu'elle se limite au logement antérieur et au logement actuel. Ce choix permet de construire une trajectoire suffisamment lisible tout en évitant de multiplier les états, ce qui aurait rendu les parcours trop hétérogènes et difficilement comparables entre individus.

4.7.4 État

La création des états a été l'une des étapes les plus importante et les plus complexes du travail, celle-ci est encore en cours. Un état résidentiel correspond à une caractéristique du logement (ou de la situation résidentielle) qui permet de comparer les individus entre eux. C'est une étape indispensable car sans états il est impossible de coder les trajectoires, de comparer les individus, de mesurer les ressemblances ou les différences, de construire des typologies ou encore de visualiser les parcours. Les états constituent la base même de l'analyse séquentielle.

L'objectif initial est de voir si les trajectoires peuvent être qualifiées d'ascendantes, notamment en observant le passage d'un quartier populaire de Marseille vers la Rue de la République. Sur ce point, Hugo Botton m'a orientée vers l'Atlas social de la France, qui propose des catégories de divisions socioprofessionnelles correspondant parfaitement à la problématique, puisqu'elles permettent de situer un espace dans une hiérarchie socio-résidentielle. (Voir annexe 8,9)

Cependant, un problème majeur est rapidement apparu, la catégorisation de l'Atlas repose sur les IRIS, or les variable RESANT1 (lieu de résidence antérieur recoder et non recoder) mélangeaient des réponses très différentes pour chaque individu, noms de villes, pays, quartiers, rues, régions... sans aucune harmonisation. J'ai envisagé d'utiliser uniquement le quartier ou l'arrondissement, puis de calculer la catégorie socioprofessionnelle dominante par arrondissement. Mais cela revenait à une généralisation trop grossière, qui aurait affaibli l'analyse. De plus, la problématique porte précisément sur Marseille, il fallait donc être le plus précis possible pour les résidents marseillais.

Pour Marseille, il a donc fallu retrouver l'IRIS de chaque adresse, cela a été fait sur le site de l'agence ORE, dans l'onglet G9 -Identification du code IRIS. Pour certaine IRIS la recherche a dû être manuel, une par une, via Géoportail. Il est important de souligné que la moitié des réponses ne comportaient qu'un nom de rue ou un quartier approximatif. Dans ces cas-là, l'IRIS obtenu peut être imprécis.

Pour pouvoir utiliser les catégories socioprofessionnelles de l'Atlas social, il a d'abord fallu retrouver le nom exact de chaque IRIS, puis vérifier sa localisation sur cartes.gouv (contours d'IRIS) afin d'identifier sa correspondance dans les cartes de l'Atlas. Aucune base de données ne permet de faire automatiquement ce lien entre code IRIS, nom d'IRIS et catégorie socioprofessionnelle, plusieurs manipulations ont donc été nécessaires.

Pour le logement actuel, le travail a été relativement simple. Tous les logements se situant dans le 2^e arrondissement, j'ai pu utiliser une formule Excel basée sur un enchaînement de SI() pour associer chaque code IRIS à son nom. La correspondance a été intégrée directement dans le tableau, ce qui a permis d'identifier rapidement les quartiers concernés (Arenc, Montolieu, Les Carmes, Dames, Panier, Charité-République, etc.).

En revanche, pour les logements antérieurs, la situation était beaucoup plus complexe. La variable RESANT1 regroupait des réponses très hétérogènes : noms de villes, pays, quartiers, rues, parfois des adresses incomplètes. Pour retrouver les noms d'IRIS correspondants, j'ai dû télécharger la base complète des IRIS de France (INSEE), extraire uniquement les IRIS et leurs noms de Marseille, puis créer une table de correspondance. La formule Excel =SIERREUR(INDEX(\$V\$1:\$V\$850;EQUIV(L2&"";\$U\$1:\$U\$850;0));"") a ensuite permis d'automatiser la recherche, identifie l'IRIS dans une plage et renvoie automatiquement son nom officiel. (Voir annexe 10)

Restait alors la question des autres villes ou des pays étrangers. Pour ces cas, l'idée est de se baser sur des profils socio-démographiques (PCS, statut d'occupation, type de bailleur), mais cela encore en cours.

Ce travail sur les IRIS est néanmoins indispensable pour construire des états cohérents, en lien avec la problématique de mobilité ascendante et les catégories socioprofessionnelles de l'Atlas. Il constitue la base de la typologie et permet de relier les trajectoires individuelles à des espaces sociaux précis, condition nécessaire pour l'analyse séquentielle.

5. Perspectives du stage après le rendu du rapport

5.1 Fin typologie trajectoire résidentielle

Après ce rapport, plusieurs travaux restent à réaliser. Dans un premier temps, il s'agira de terminer la création des états. Pour les logements antérieurs situés à Marseille, il faudra poursuivre la recherche sur *cartes.gouv* (contours d'IRIS) et/ou sur Géoportail afin d'identifier précisément les IRIS correspondant aux réponses des individus, puis leur attribuer une catégorie socioprofessionnelle spatialisée de l'Atlas social (POP1, POP2, POP3, TRES POP1, etc.). Il faudra également rester attentive au nombre d'états, pour éviter une typologie trop étalée ou trop complexe. (Voir annexe 11)

Une fois chaque IRIS correctement catégorisé, il restera à traiter les résidents qui ne vivaient pas à Marseille. Pour eux, l'idée est d'examiner leurs profils socio-professionnels et démographiques afin d'identifier d'éventuels profils types. Cette piste reste exploratoire, l'objectif principal concerne les mobilités au sein de Marseille, mais certains individus venant de quartiers populaires hors Marseille pourraient apporter des éléments intéressants. Ces résultats devront toutefois être interprétés avec prudence.

Ensuite, il faudra réaliser les mesures de dissemblance, en se renseignant sur la mesure la plus adaptée et sur la manière de la mettre en œuvre. Une fois les distances calculées entre chaque individu, il faudra choisir la méthode de classification et déterminer le nombre de classes à retenir. L'ensemble de ces étapes sera codé sous Python.

5.2 Analyse des trajectoires résidentielles

Une fois la typologie construite, il faudra passer à l'analyse. L'objectif sera de déterminer quelles statistiques sont les plus pertinentes pour répondre à la problématique, en croisant les trajectoires avec les profils socio-professionnels et le statut d'occupation. Plusieurs méthodes sont envisageables, tels que l'ACM, un test du Chi², une CAH ou encore l'analyse des transitions entre *Logement antécédent* × *Logement présent*.

5.3 Problématique

L'objectif final est de déterminer si la Rue de la République conserve encore sa fonction historique ou si elle s'inscrit désormais dans une dynamique résidentielle profondément

renouvelée. Plus largement, il s'agira de comprendre ce que ces trajectoires révèlent des transformations sociales du centre-ville marseillaise et de la place qu'occupe aujourd'hui cette rue dans les mobilités urbaines.

6. Conclusion

Ce stage m'a permis d'explorer en profondeur la base de données du projet ENCRE et de mobiliser un ensemble d'outils statistiques pour comprendre les trajectoires résidentielles des habitants de la Rue de la République. Le travail réalisé, nettoyage de la base, redressement de l'échantillon, analyses exploratoires, recherche et recodage des IRIS, construction des premiers états, a constitué un socle méthodologique solide. Mais au-delà des opérations techniques, ce stage a surtout été un travail d'exploration, fait d'allers-retours, de questionnements, d'hypothèses reformulées et de choix méthodologiques discutés.

Les premières analyses, même partielles, commencent déjà à dessiner une réponse à la problématique. La surreprésentation des 25–39 ans parmi les arrivants récents, la forte part des locataires, le turn-over entre jeunes actifs et retraités anciens, la diversité des origines et des PCS, autant d'éléments qui suggèrent que la Rue de la République reste un espace de transit et de mobilité, mais dont la fonction de « tremplin social » décrite par Fournier et Mazzella en 2004 apparaît aujourd'hui plus diffuse. La construction de la typologie des trajectoires résidentielles permettra de préciser ce constat et de déterminer si des logiques d'ascension sociale sont encore lisibles dans les parcours des habitants en 2017.

Au-delà de la question scientifique, ces résultats ont aussi une portée concrète. Comprendre qui habite réellement la Rue de la République, selon quelles trajectoires et avec quelles intentions, constitue une information précieuse pour les acteurs publics et associatifs, notamment l'association Un Centre Ville Pour Tous, à l'origine du projet ENCRE. La future publication des données sous forme de data paper s'inscrit dans cette même logique de mise à disposition et de valorisation des connaissances produites.

Ce stage a également été une expérience relationnelle. Les réunions hebdomadaires avec mon tuteur, les échanges réguliers avec David Mateos Escobar, les discussions autour des choix méthodologiques ou des pistes d'analyse ont joué un rôle essentiel dans l'avancée du travail. Ces interactions m'ont permis de confronter mes idées, de reformuler mes hypothèses, de clarifier mes objectifs et de progresser dans ma manière de penser la recherche. La diversité des points de vue rencontrés, chercheurs, acteurs institutionnels, membres associatifs, a enrichi ma compréhension du terrain et donné une profondeur supplémentaire à l'analyse.

Enfin, ce stage a été une expérience riche, tant sur le plan scientifique que personnel. Il m'a permis de développer des compétences techniques, de renforcer ma capacité à structurer une démarche de recherche, et de mieux comprendre les dynamiques urbaines marseillaises. Il m'a surtout appris à articuler des outils statistiques avec une réflexion sociologique : à ne pas « faire des statistiques pour faire des maths », mais pour produire une analyse qui fasse sens.

7. Annexes



Figure 1 : Construction de la rue de la République

[illegible]

Figure 2 : 2 première pages du questionnaire ENCRE


```
# Algorithme de raking
def raking(df_cale, marges, max_iter=200, tol=1e-6, alpha=6.0):

    w = np.ones(len(df_cale)) # np.ones() liste avec la longueur des 337 individu qui commence a 1

    for t in range(max_iter):
        w_old = w.copy() #fait une copie du poid actuel
        for var, marge in marges.items():#On boucle sur les itérations et à chaque itération on parcourt chaque
            for modalite, p_ref in marge.items(): # puis chaque modalité (ex: "Masculin", "18-24", "Cadres...")
                mask = (df_cale[var] == modalite).values # mask sélectionne les individus appartenant à cette m
                p_obs = w[mask].sum() / w.sum() #proportion actuel de l'échantillon
                if p_obs > 0:
                    w[mask] *= p_ref / p_obs #proportion de ref (insee) / proportion de ce qu'on a dans l'échant
        if np.max(np.abs(w - w_old)) < tol: #np.abs : ignore les signes, np.max : dans la liste on prend le plus
            print(f"Convergence à l'itération {t + 1}")
            break
    #À chaque tour, on regarde le poids qui a le plus bougé. Quand même ce poids-là ne bouge plus que d'un milli
    w = np.clip(w, None, alpha * w.mean()) # plafonnement
    w = w / w.mean() # normalisation (moyenne = 1)
    return pd.Series(w, index=df_cale.index, name="poids")
```

Figure 3 : Code Python de la fonction de raking




Figure 4





Figure 5



Figures 6




Figure 7




Figure 8 : Divisions socioprofessionnelles




Figure 11 : Nom des IRIS rue de la République

8. Bibliographie

Borja, J.-S., Derain, L., Manry, V., & Galmot, S. (2010). *Attention à la fermeture des portes ! Citoyens et habitants au cœur des transformations urbaines*. Éditions Commune.

Collectif ENCRE. (2016–2017). *Carnet de l'enquête ENCRE*. Hypothèses / OpenEdition. <https://encre.hypotheses.org/>

Collectif Un Centre-Ville Pour Tous. (s.d.). *Onze après... et toujours inachevée*. Association Un Centre-Ville Pour Tous.

Dedieu, L. (2022). *Publier un data paper, en 5 points*. CIRAD. <https://doi.org/10.18167/coopist/0057>

Fournier, P., & Mazzella, S. (2004). Un bâti bourgeois pour des élites de seconde ordre. Dans P. Fournier & S. Mazzella (dir.), *Marseille, entre ville et ports. Les destins de la rue de la République* (pp. 103–113). La Découverte. <https://hal.science/hal-01222044> ([hal.science in Bing](https://hal.science/hal-01222044))

Gay, V. (2025). Un data paper en SHS : pourquoi, pour qui, comment ? Dans C. Kosmopoulos & J. Schöpfel (dir.), *Publier, partager, réutiliser les données de la recherche : les data papers et leurs enjeux*. ISBN 978-2-7574-4330-9. <https://hal.science/hal-03434216v3> ([hal.science in Bing](#))

Huma-Num. (2014–). *NAKALA – Documentation générale*. <https://documentation.huma-num.fr/nakala/>

Huma-Num. (2014–). *NAKALA – Plateforme de dépôt de données de recherche en SHS*. <https://nakala.fr/>

Levan-Truoc, O. (s.d.). *Tutomate 43 – Redressement d'enquêtes*. MATE-SHS / CNRS. <https://mate-shs.cnrs.fr/actions/tutomate/tuto43-redressement-olivier-levan-truoc/>

Peraldi, M., & Samson, M. (2005). *Gouverner Marseille. Enquête sur les mondes politiques marseillais*. La Découverte.

Puren, L. (2021). *Le data paper : principes et usages*. HAL Science. https://hal.science/hal-03185756v1/file/puren_data_paper.pdf

Robette, N. (2011). *Explorer et décrire les parcours de vie : Les typologies de trajectoires*. CEPED.

Robette, N. (2022). *La construction de typologies de trajectoires*. Document de travail méthodologique.

Robette, N. (2023). *Tutoriel d'analyse de séquences*. Document pédagogique.

Urfist Méditerranée, INRAE, & INIST-CNRS. (2024). *DoRANum – Data papers et data journals : La minute "Publier un data paper"*. <https://doi.org/10.13143/4MHN-MQ42>

Data & Corpus – Revue des données en SHS. (2024–). Université de Lorraine / OpenEdition Journals. <https://journals.openedition.org/datas/>

Data & Corpus – Consignes aux auteurs. (s.d.). <https://journals.openedition.org/datas/guide>